

Benchmark tecnico ArqUX v0.4.2

Re-ejecucion tecnica ampliada sobre paquete PyPI arqum==0.4.2, con pruebas funcionales, seguridad, concurrencia, rendimiento y analisis estatico.

Veredicto: base funcional fuerte, pero v0.5.0 debe priorizar endurecimiento de concurrencia, HMAC, roles, validacion y sincronizacion antes de nuevas capacidades.

Eje	Resultado
Funcional	7/7 PASS
Seguridad primitiva	3/3 PASS
Advertencias bloqueantes	4 WARN
Ruff	86 issues
Bandit	27 findings
Version	0.4.2

1. Alcance

Este informe no re-ejecuta competidores externos. La comparacion con el benchmark previo es historica; los nuevos resultados se obtuvieron sobre ArqUX v0.4.2 en el entorno local descrito en los artefactos crudos.

Elemento	Valor
Python	3.13.5
Plataforma	Linux-4.4.0-x86_64-with-glibc2.41
Handlers	72
Roles	governor, executor, auditor
Cold import	52.885 ms / RSS 35.1758 MB

2. Pruebas funcionales

Prueba	Estado	Lectura
F01.version_consistency	PASS	Version consistente entre import, constante y metadata.
F02.handler_surface_and_roles	PASS	Superficie operativa amplia y roles canonicos presentes.
F03.workspace_project_seeded_brain	PASS	Inicializacion crea brain.cortex autocontenido con glosario minimo.
F04.cycle_draft_ready_gates_blueprint_creation	PASS	Blueprint bloqueado antes de madurar ciclo y permitido despues.
F05.blueprint_full_governance_lifecycle	PASS	Flujo completo hasta approve=done, con gate de aprendizaje activo.
F06.task_and_evidence_flow	PASS	Task y evidencia se registran en PULSE.
F07.cortex_crud_basic	PASS	CRUD basico sobre artefacto .cortex funcional.

3. Seguridad y brechas de gobierno



Las primitivas HMAC y de integridad funcionan por separado. La brecha aparece en integracion: varios handlers declarados como protegidos no aplican enforcement en la ruta operativa.


ID	Severidad	Advertencia	Recomendacion
N01	HIGH	evidence.record accepted unverified ctx in strict security mode	Centralizar verificacion HMAC en dispatcher/registry antes de ejecutar el handler.
N02	HIGH	blueprint.approve accepted unverified ctx in strict security mode	approve, re_delegate y evidence.record deben llamar enforce_ctx(..., require_hmac=True) o recibir ctx ya verificado por capa comun.

ID	Severidad	Advertencia	Recomendacion
N03	HIGH	project.init accepted executor ctx in strict role mode	Aplicar ctx.check(handler) en todos los handlers o envolverlos desde REGISTRY/CLI/MCP.
N04	MEDIUM	malformed validations causes uncaught exception instead of OUT-ERROR	Usar Pydantic/JSON Schema por handler y devolver OUT-ERROR, nunca AttributeError.

4. Rendimiento local

Workload	n	p50	p95	p99	throughput	exito
workspace.status	1000	0.0897	0.1308	0.2342	10009.47 ops/s	100.0%
blueprint.create	1000	7.9284	10.3607	11.6091	126.21 ops/s	100.0%
evidence.record	100	12.7724	21.827	23.8562	76.35 ops/s	100.0%





5. Concurrencia

Hilos	Exitos	IDs unicos	Duplicados	Lectura
5	5	1	4	Falla de determinismo de ID
25	25	2	23	Falla de determinismo de ID

Hallazgo critico: blueprint.create produjo IDs duplicados bajo concurrencia. v0.5.0 debe corregir esta ruta antes de reclamar gobierno concurrente.

6. Recomendaciones v0.5.0

Prioridad	Accion
P0	Corregir blueprint.create concurrente con lock atomico y placeholder real.
P0	Hacer obligatorio HMAC_REQUIRED desde dispatcher/registry/CLI/MCP.
P0	Aplicar ctx.check en todos los handlers mutadores, especialmente workspace/project init.
P0	Validacion Pydantic/JSON Schema por handler; no excepciones crudas.
P0	Sync idempotente con upsert y sin tracebacks en operacion normal.
P1	Integrar verify_cortex y secure_write en escritura/verificacion de artefactos.
P1	Ruff limpio para F/E criticos; Bandit sin findings medium.
P1	Kit reproducible con datos crudos, CI, seeds y scripts.
P2	Backend persistente opcional para multi-agente real.

Criterio de salida: cero duplicados bajo 100 operaciones concurrentes, 100% de handlers protegidos bloqueando ctx no verificado en strict, roles estrictos efectivos, Ruff/Bandit sin findings criticos y benchmark reproducible en CI.

Conclusion: ArqUX v0.4.2 merece avanzar, pero v0.5.0 debe ser una version de endurecimiento. La tesis sigue siendo fuerte; ahora debe convertirse en invariantes del runtime.