

Benchmark comparativo tecnico y estrategico - ArqUX v0.4.2

Diferenciacion, madurez, riesgos y ruta v0.5.0 frente a LangGraph, CrewAI, OpenAI Agents SDK y AutoGen

Evaluacion tecnica asistida

2026-07-09

- [Resumen ejecutivo](#)
- [1. Tesis de comparacion](#)
- [2. Soluciones evaluadas](#)
- [3. Metodologia](#)
 - [3.1 Limitaciones](#)
- [4. Resultados tecnicos ejecutados sobre ArqUX v0.4.2](#)
 - [4.1 Pruebas funcionales](#)
 - [4.2 Seguridad positiva](#)
 - [4.3 Pruebas negativas con advertencias bloqueantes](#)
 - [4.4 Rendimiento ArqUX ejecutado](#)
- [5. Sondas dinamicas multi-framework sin LLM](#)
- [6. Matriz comparativa de capacidades](#)
 - [6.1 Matriz detallada 0-5](#)
 - [6.2 Lectura critica por competidor](#)
 - [LangGraph](#)
 - [CrewAI](#)
 - [OpenAI Agents SDK](#)
 - [AutoGen](#)
- [7. Diferenciadores reales de ArqUX](#)
- [8. Desventajas y riesgos actuales](#)
- [9. Alineacion con necesidades de la industria](#)
- [10. Recomendaciones para v0.5.0](#)
- [11. Roadmap propuesto v0.5.0](#)
 - [11.1 Criterio de salida v0.5.0](#)
 - [11.2 Formulacion recomendada para posicionamiento](#)
- [12. Conclusion](#)
- [Apendice A. Fuentes principales](#)
- [Apendice B. Artefactos generados](#)

Resumen ejecutivo

Este informe corrige el enfoque del benchmark anterior. La pregunta central no es si ArqUX es “mas rapido” que frameworks reconocidos; la pregunta correcta es si ArqUX posee una propuesta diferencial verificable frente al mercado, cuales son sus ventajas y desventajas, y si su direccion tecnica corresponde con lo que la industria esta demandando para agentes productivos.

La conclusion principal es clara: **ArqUX v0.4.2 no debe posicionarse como reemplazo directo de LangGraph, CrewAI, OpenAI Agents SDK o AutoGen. Su posicion mas fuerte es como capa de gobierno interoperable para agentes: identidad, contrato, memoria CORTEX, evidencia, lifecycle y aprendizaje operativo.**

En comparacion con el benchmark anterior, que reportaba cierre de bugs en ArqUX v0.4.0 y advertia que no debia interpretarse como superioridad universal, esta evaluacion amplia el criterio hacia mercado, industria, diferenciacion y madurez. El documento base reportaba, entre otros puntos, 6/6 hallazgos cerrados, 100% de exito en stress 1k ops, p50 de 0.94 ms para v0.4.0, y recomendaba reproducibilidad, auditoria externa, CI, quickstart y ejemplos reales como condiciones de maduracion.

Juicio tecnico: ArqUX tiene una tesis potente y alineada con el futuro de la industria, pero v0.4.2 aun no tiene madurez suficiente para reclamar production-ready. Debe llegar a v0.5.0 cerrando fallas de enforcement, concurrencia, validacion, CI, documentacion y pruebas reproducibles.

1. Tesis de comparacion

ArqUX debe compararse en dos niveles:

- 1. **Nivel runtime:** construccion, ejecucion y coordinacion de agentes.
- 2. **Nivel gobierno:** identidad, permisos, contratos, evidencia, memoria, integridad y reproducibilidad institucional.

Los frameworks reconocidos dominan mejor el primer nivel. ArqUX tiene mejor oportunidad en el segundo.

Tesis defendible: ArqUX no gana por reemplazar los runtimes lideres. Gana si demuestra que puede gobernarlos.

2. Soluciones evaluadas

Solucion	Version / fuente	Lectura de mercado
ArqUX	0.4.2	Capa de gobierno para agentes con identidad, contrato, CORTEX, Blueprint lifecycle, evidencia y MCP. Estado PyPI: Beta.
LangGraph	1.2.8	Runtime low-level para agentes stateful, long-running, durable execution, streaming, persistence, memory y human-in-the-loop.
CrewAI	1.15.2	Framework de crews y flows, fuerte en productividad multiagente, comunidad, enterprise console/AMP y automatizacion de procesos.
OpenAI Agents SDK	0.18.0	SDK liviano con agents, handoffs, tools, guardrails, sessions, tracing, MCP y sandbox agents. Muy fuerte en DX y ecosistema OpenAI.
AutoGen AgentChat	0.7.5	Framework Microsoft para aplicaciones single/multi-agent, AgentChat, Core event-driven, Studio y extensiones como MCP Workbench y Docker executor.

3. Metodologia


Se aplicaron cuatro capas de evaluacion:

- 1. **Pruebas dinamicas ejecutadas sobre ArqUX v0.4.2:** funcionales, seguridad, negativas, rendimiento y estres concurrente.
- 2. **Sondas dinamicas sin LLM externo:** instalacion/import/smoke de ArqUX, LangGraph, OpenAI Agents SDK y AutoGen AgentChat. CrewAI no completo instalacion en el entorno dentro de la ventana ejecutada; se conserva como limitacion y se evalua por documentacion oficial y PyPI.
- 3. **Matriz de capacidades:** puntuacion 0-5 por eje, basada en documentacion oficial, PyPI, pruebas dinamicas y lectura tecnica del proyecto.
- 4. **Alineacion industrial:** contraste con MCP, guardrails, human-in-the-loop, tracing, seguridad agentica, memoria persistente, integridad y controles deterministas.

3.1 Limitaciones

- No se hicieron llamadas a modelos externos ni se midieron tareas con LLM, para evitar variabilidad por red, proveedor, modelo y credenciales.
- La comparacion cuantitativa de performance entre frameworks no debe leerse como ranking universal: cada framework resuelve una capa diferente.
- CrewAI no completo instalacion dinamica en el contenedor durante la ejecucion disponible; su comparacion se basa en documentacion oficial y PyPI.
- La puntuacion 0-5 no es una verdad absoluta; es una rubrica explicita para detectar posicionamiento relativo.

4. Resultados tecnicos ejecutados sobre ArqUX v0.4.2



4.1 Pruebas funcionales

ArqUX v0.4.2 paso 7/7 pruebas funcionales: version consistente, superficie de handlers/roles, workspace/project/brain, ciclo draft-ready, lifecycle de Blueprint, flujo task/evidence y CRUD basico CORTEX.

4.2 Seguridad positiva

Paso 3/3 pruebas positivas de seguridad: primitivas HMAC/replay/tamper, integridad CORTEX y enforcement de identity.record en modo estricto.

4.3 Pruebas negativas con advertencias bloqueantes

Prueba	Estado	Interpretacion
N01.hmac_required_not_enforced_on_evidence_record	WARN	evidence.record accepted unverified ctx in strict security mode
N02.hmac_required_not_enforced_on_blueprint_approve	WARN	blueprint.approve accepted unverified ctx in strict security mode
N03.strict_role_not_enforced_on_project_init	WARN	project.init accepted executor ctx in strict role mode
N04.blueprint_define_malformed_validations_uncaught	WARN	malformed validations causes uncaught exception instead of OUT-ERROR

Lectura: la presencia de HMAC primitives no basta si algunos handlers mutantes no lo aplican de forma obligatoria. Para v0.5.0, el enforcement debe moverse a un gateway comun o dispatcher, no depender de cada handler.

4.4 Rendimiento ArqUX ejecutado

Workload	n	p50 ms	p95 ms	p99 ms	throughput ops/s	exito	duplicados
cold_import							
workspace_status_1k_direct	1000	0.0897	0.1308	0.2342	10009.47	1.0	
blueprint_create_1k_seq	1000	7.9284	10.3607	11.6091	126.21	1.0	
evidence_record_100_seq	100	12.7724	21.827	23.8562	76.35	1.0	
blueprint_create_concurrent_5	5	34.5711	35.4183	35.4253		5	4
blueprint_create_concurrent_25	25	170.6389	172.9362	173.9169		25	23


Lectura: workspace.status es extremadamente rapido por ser lectura liviana. blueprint.create y evidence.record muestran costos razonables para gobierno interactivo, pero el estres concurrente revela un defecto critico: IDs duplicados bajo 5 y 25 hilos.

5. Sondas dinamicas multi-framework sin LLM

Framework	Version	Import OK	Smoke OK	Import ms	Site packages MB	Dist count	Nota
ArqUX	0.4.2	True	True	36.318	66.98	39	
LangGraph	1.2.8	True	True	0.237	76.81	38	
OpenAI Agents SDK	0.18.0	True	True	1636.956	76.61	44	
AutoGen AgentChat	0.7.5	True	True	1.099	51.48	15	
CrewAI	no instalado	False	False	None	213.37	35	ModuleNotFoundError("No module named 'crewai'")

Lectura: LangGraph, OpenAI Agents SDK y AutoGen pasaron sondas sin LLM. ArqUX importo correctamente y expuso version. CrewAI quedo como no concluido en la sonda local; no debe usarse este dato para degradar tecnicamente a CrewAI, sino como limitacion del entorno de prueba.

6. Matriz comparativa de capacidades



Comparativa por familias

Framework	Orquestacion	Gobierno / auditoria	Madurez mercado	Promedio
ArqUX v0.4.2	3.0	4.0	2.0	3.08
LangGraph 1.2.8	4.4	2.0	5.0	3.75
CrewAI 1.15.2	4.0	2.5	4.0	3.5
OpenAI Agents SDK 0.18.0	4.2	2.75	5.0	3.92
AutoGen AgentChat 0.7.5	3.8	1.25	3.67	2.92

6.1 Matriz detallada 0-5

Eje	ArqUX v0.4.2	LangGraph 1.2.8	CrewAI 1.15.2	OpenAI Agents SDK 0.18.0	AutoGen AgentChat 0.7.5
Runtime / orquestacion	2	5	4	4	4
Persistencia / estado	4	5	4	4	3
Human-in-the-loop	2	5	4	4	3
Multiagente	3	4	5	4	5
MCP / herramientas	4	3	3	5	4
Guardrails / politica	3	3	4	5	2
Identidad y gobierno	5	1	2	2	1
Evidencia auditable	4	2	2	2	1
Integridad memoria	4	2	2	2	1
Observabilidad	2	5	4	5	3
Documentacion / ecosistema	2	5	4	5	4
Madurez / adopcion	2	5	4	5	4

6.2 Lectura critica por competidor

LangGraph

Es el competidor mas fuerte en runtime stateful, durable execution, persistence, memory, streaming y human-in-the-loop. Para ArqUX, LangGraph no deberia ser visto como enemigo principal sino como runtime ideal para integracion: ArqUX puede aportar gobierno, identidad, evidencia e integridad sobre flujos LangGraph.

CrewAI

Tiene mejor productividad y narrativa de adopcion para equipos que quieren crews, flows, tasks, guardrails, memory, knowledge y despliegue enterprise. ArqUX compite peor en comunidad, ejemplos, onboarding y comercializacion. Puede diferenciarse si ofrece auditoria e identidad verificable mas fuertes que la nocion de rol/crew.


OpenAI Agents SDK

Tiene una ventaja enorme en simplicidad, tracing, guardrails, MCP, sessions, handoffs y sandbox agents. ArqUX no deberia intentar superar esa experiencia base; deberia integrarse como capa de gobierno externo, especialmente para evidencia persistente, contratos de identidad y memoria verificable.

AutoGen

Es fuerte en colaboracion multiagente, AgentChat, Core event-driven, Studio y extensiones. ArqUX puede aportar estructura de decision, evidencia y memoria institucional sobre conversaciones multiagente que, de otro modo, quedan mas centradas en interaccion que en gobierno documental.

7. Diferenciadores reales de ArqUX



Posicionamiento relativo

Los diferenciadores reales no son velocidad ni ecosistema. Son:

1. **Identidad como frontera operacional:** el agente no es una variable de prompt; es un actor con rol, limites y contrato.
2. **Blueprint como decision gobernada:** evita saltar directo de intencion a ejecucion.
3. **CORTEX como memoria institucional:** conserva decisiones, evidencia, lecciones y estado fuera de la conversacion temporal.
4. **Evidencia como artefacto:** no solo logs; busca materializar evidencia verificable.
5. **Handoff como control de responsabilidad:** reduce confusion entre auditor, ejecutor, documentador y gobernador.
6. **MCP como canal de gobierno:** no solo herramientas, sino operaciones de control sobre identidad, ciclo, memoria y evidencia.

8. Desventajas y riesgos actuales

1. **No es un runtime competitivo completo:** LangGraph, CrewAI, OpenAI Agents SDK y AutoGen tienen mejor ejecucion, ecosistema y experiencia de desarrollo.
2. **Madurez baja:** PyPI lo declara Beta, y aun falta documentacion de adopcion, CI fuerte y ejemplos reproducibles.
3. **Enforcement incompleto:** evidence.record y blueprint.approve aceptaron contexto no verificado en modo estricto durante pruebas negativas.
4. **Concurrencia critica:** blueprint.create genero IDs duplicados bajo concurrencia.

- 5. **Roles insuficientemente aplicados:** project.init acepto un contexto executor en modo estricto.
- 6. **Errores crudos:** entradas malformadas pueden producir excepciones no gobernadas.
- 7. **Deuda estatica:** ruff/bandit detectaron issues que deben ser tratados antes de claims enterprise.
- 8. **Jerga propietaria:** Hexagon, CORTEX, Blueprint, sigilos y roles necesitan traduccion didactica para adopcion.

9. Alineacion con necesidades de la industria

La direccion conceptual de ArqUX esta bien alineada con la industria por cinco motivos:

- 1. **MCP esta consolidandose como canal estandar de conexion entre aplicaciones IA y sistemas externos.** ArqUX ya se posiciona alrededor de MCP como capa de gobierno.
- 2. **Los agentes estan pasando de chat a operacion.** Esto vuelve criticas identidad, permisos, trazabilidad, memoria y recuperacion.
- 3. **La seguridad agentic exige controles estructurales, no solo guardrails probabilisticos.** Investigacion reciente sobre workflows autenticados plantea la necesidad de autenticidad criptografica y policy enforcement en fronteras de prompts, tools, data y context.
- 4. **La memoria persistente es una nueva superficie de ataque.** Investigacion reciente sobre containment gap destaca la ausencia de garantias nativas de integridad de memoria en frameworks agentic evaluados y muestra el riesgo de memory poisoning.
- 5. **La empresa requiere auditabilidad.** Las soluciones lideres resuelven tracing y observabilidad, pero no siempre evidencia institucional verificable ni memoria gobernada como objeto central.

Veredicto de correspondencia futura: alto potencial, siempre que ArqUX no intente ser otro runtime mas. Su lugar futuro es ser una capa de gobierno interoperable.

10. Recomendaciones para v0.5.0

Prioridad	Severidad	Accion	Implementacion	Valor
P0	Bloqueante	ID atomico concurrente	Encapsular blueprint/task/evidence ID creation con lock real, reserva atomica y prueba 5/25/100 hilos	Evita colision de artefactos de gobierno
P0	Bloqueante	Security dispatcher obligatorio	Aplicar HMAC_REQUIRED y roles en un gateway comun antes del handler, no como disciplina voluntaria del handler	Cierra bypass en evidence.record y blueprint.approve
P0	Bloqueante	Roles estrictos por handler mutante	Matriz role x handler, project.init solo governor, approve auditor/governor, evidence actor verificado	Evita escalamiento de permisos
P0	Bloqueante	Errores estructurados	Toda validacion malformada debe retornar	Estabilidad y DX enterprise

Prioridad	Severidad	Accion	Implementacion	Valor
			CortexOUT.error, no excepciones crudas	
P0	Bloqueante	CI de calidad y seguridad	pytest, stress concurrente, ruff, mypy, bandit, coverage y release gate	Reduce regresiones y deuda visible
P1	Alta	Benchmark reproducible publico	Scripts, dataset, seeds, logs, comandos, raw JSON, plots, ambiente y CI matrix	Credibilidad externa
P1	Alta	Adapters a frameworks lideres	Ejemplos ArqUX+LangGraph, ArqUX+OpenAI Agents, ArqUX+CrewAI, ArqUX+AutoGen	Posiciona ArqUX como capa de gobierno interoperable
P1	Alta	Threat model formal	STRIDE/OWASP LLM + memory poisoning + MCP tool poisoning + replay + tamper	Alineacion con industria y seguridad
P1	Alta	Docs por audiencia	Quickstart 30 min, arquitectura, API, glosario, cookbook, patrones de adopcion	Reduce friccion de jerga
P2	Media	Observabilidad	Eventos CORTEX exportables a OpenTelemetry/ LangSmith/JSONL	No competir contra tracing, integrarse con tracing
P2	Media	SBOM y provenance	pip audit, cyclonedx, firma de artefactos, release attestations	Confianza supply-chain
P2	Media	Dashboard de auditoria	Vista de identidad, blueprint, evidencia, tamper, handoffs, lessons	Valor enterprise tangible

11. Roadmap propuesto v0.5.0

11.1 Criterio de salida v0.5.0

ArqUX v0.5.0 deberia liberarse solo si cumple:

- 0 duplicados en 100 blueprints concurrentes.
- 100% enforcement HMAC para handlers declarados en HMAC_REQUIRED.
- 100% enforcement de roles en handlers mutantes.
- 0 excepciones crudas en validaciones negativas conocidas.
- CI publico con pytest, ruff, mypy, bandit, coverage y stress tests.
- Benchmark reproducible con scripts, datos crudos, comandos, entorno y graficos.
- Quickstart de 30 minutos que demuestre identidad, blueprint, task, evidencia y CORTEX.
- Al menos dos adapters demostrativos: ArqUX+LangGraph y ArqUX+OpenAI Agents SDK.

11.2 Formulacion recomendada para posicionamiento

ArqUX es una capa de gobierno para agentes, no un replacement de runtimes agentic. Su valor esta en hacer operable y verificable la responsabilidad de agentes que deciden, ejecutan, aprenden y dejan evidencia.

12. Conclusion

ArqUX v0.4.2 posee un diferencial tecnico real: intenta convertir la operacion agentica en una arquitectura gobernada. Esa tesis esta bien alineada con el futuro de la industria, especialmente por MCP, integridad de memoria, evidencia, identidad y compliance.

Pero la version actual no debe reclamar madurez productiva. Las pruebas ejecutadas muestran una base funcional positiva y una propuesta clara, pero tambien defectos bloqueantes en enforcement, concurrencia y validacion. La mejor estrategia para v0.5.0 no es competir frontalmente contra LangGraph, CrewAI, OpenAI Agents SDK o AutoGen. Es integrarse con ellos y demostrar que ArqUX agrega una capa que el mercado va a necesitar: gobierno verificable.

Apendice A. Fuentes principales

- Benchmark base compartido por el usuario: Benchmark_ArqUX_v3_Benchmark_Comparativo(1).pdf.
- PyPI ArqUX 0.4.2: <https://pypi.org/project/arqux/>
- Repositorio ArqUX: <https://github.com/FidelErnesto03/arqux>
- LangGraph docs: <https://docs.langchain.com/oss/python/langgraph/overview>
- PyPI LangGraph: <https://pypi.org/project/langgraph/>
- CrewAI docs: <https://docs.crewai.com/>
- PyPI CrewAI: <https://pypi.org/project/crewai/>
- OpenAI Agents SDK docs: <https://openai.github.io/openai-agents-python/>
- PyPI OpenAI Agents SDK: <https://pypi.org/project/openai-agents/>
- AutoGen docs: <https://microsoft.github.io/autogen/stable/>
- PyPI AutoGen AgentChat: <https://pypi.org/project/autogen-agentchat/>
- MCP official docs: <https://modelcontextprotocol.io/docs/getting-started/intro>
- Authenticated Workflows: A Systems Approach to Protecting Agentic AI, arXiv 2602.10465.
- The Containment Gap: How Deployed Agentic AI Frameworks Fail Public-Facing Safety Requirements, arXiv 2606.12797.

Apendice B. Artefactos generados

- matriz_capacidades.csv
- roadmap_v0_5_0.csv
- sondas_dinamicas.csv
- market_probe_import.json
- market_probe_installed.json
- arqux_v042_benchmark_results.json
- Graficos en artifacts/